



Université Mohammed V — Rabat

**École Nationale Supérieure d'Informatique et d'Analyse des
Systèmes**

MÉMOIRE DE PROJET DE FIN D'ÉTUDES

POUR L'OBTENTION DU TITRE : INGÉNIEUR D'ÉTAT EN INFORMATIQUE

Option : Business Intelligence & Analytics

Conception et développement d'un agent IA pour la détection de fraude dans le domaine de la monétique

Réalisé par : Aya LEBSIRE

Soutenu le : 10/07/2026

Encadré par :

Pr. Zakariae ABBAD (Encadrant de
l'ENSIAS)
Mme Samia NACIRI (Encadrante de D&A
technologies)

Membres du Jury :

M. Si Lhoussain AOURAGH Président
M. Abdallah EL MANOUAR Examineur

Année Universitaire 2025 / 2026

Dédicace

*À mes très chers **parents**,
à ceux dont l'amour inconditionnel a été ma première force,
à ceux dont les sacrifices silencieux ont tracé mon chemin vers la réussite,
à ceux qui ont toujours cru en moi et m'ont guidée à chaque étape de ma vie,
Vous êtes ma lumière, ma force et mon refuge.*

*À ma chère sœur **Douaa**,
pour ton affection sincère, ta présence rassurante et ton soutien constant,
qui ont été pour moi une source d'inspiration et de motivation au quotidien.*

*À mes chers frères : **Mehdi, Mouhammed et Ghayet**,
pour votre amour fraternel, votre bienveillance et votre soutien sans faille,
qui m'ont accompagnée dans les moments de doute comme dans les réussites.*

*À mes chères amies **Hafsa et Najia**,
pour votre amitié sincère, votre fidélité et vos encouragements précieux,
qui ont rendu ce parcours plus léger et plus humain.*

*Enfin, à toutes les personnes qui ont croisé mon chemin,
qui m'ont inspirée, soutenue ou encouragée de près ou de loin,
je dédie humblement ce travail,
fruit de plusieurs années d'efforts, de persévérance et d'ambition.*

Remerciements

*Je rends grâce à **Allah le Tout-Puissant**, de m'avoir accordé la force, la patience et la santé nécessaires pour mener à bien ce travail.*

*Je tiens à exprimer ma profonde gratitude à mon encadrant **M. Zakariae ABBAD**, pour son accompagnement, sa rigueur scientifique, ses précieux conseils et sa disponibilité tout au long de cette période.*

*Je remercie chaleureusement **M. Driss LAHRICHI**, Directeur et Fondateur de D&A Technologies, pour son accueil au sein de l'entreprise ainsi que pour la confiance qu'il m'a accordée en me permettant d'effectuer ce stage dans un environnement professionnel enrichissant.*

*Mes sincères remerciements vont également à **Mme Samia NACIRI**, encadrante externe, pour sa patience, sa disponibilité et ses orientations pertinentes qui ont grandement contribué à la réussite de ce travail.*

*Je remercie **M. Si Lhoussain AOURAGH** et **M. Abdellah EL MANOUAR**, membres du jury, pour l'honneur qu'ils me font en acceptant d'évaluer ce travail.*

*J'adresse également mes remerciements à l'ensemble du **corps professoral** ainsi qu'au personnel administratif et technique de l'**ENSIAS**, pour la qualité de la formation et leur accompagnement tout au long de mon parcours académique.*

*Enfin, je remercie chaleureusement toute l'**équipe Data de D&A Technologies** pour leur accueil, leur soutien quotidien et leur collaboration, qui ont largement contribué à la réalisation de ce projet.*

Résumé

Ce projet, réalisé au sein de D&A Technologies pour l'un de ses clients spécialisés dans la gestion des cartes carburant, porte sur la conception et le développement d'un agent intelligent de détection de fraude sur les transactions monétiques.

Conformément au paradigme des agents intelligents défini par Russell et Norvig, le système **perçoit** son environnement à travers un flux continu de transactions transmis par Apache Kafka, **raisonne** en appliquant conjointement un moteur de dix-sept règles métier et cinq modèles de Machine Learning spécialisés dans la détection de comportements frauduleux complexes propres au profil de chaque carte, puis **agit** en produisant une décision de détection accompagnée d'une description explicative en langage naturel, générée par le Grand Modèle de Langage LLaMA 3.3 70B via LangChain. L'ensemble des résultats est centralisé dans une base de données PostgreSQL et restitué aux experts métier à travers un tableau de bord analytique interactif.

Par rapport au système existant fondé exclusivement sur des règles statiques appliquées en mode batch quotidien, la solution apporte une valeur ajoutée significative : détection en temps réel, adaptation aux profils individuels de chaque carte, génération automatique d'explications compréhensibles par des utilisateurs non spécialistes, et traçabilité complète des décisions produites.

Mots-clés : agent intelligent, détection de fraude, règles métier, grand modèle de langage, traitement en temps réel, Apache Kafka, tableau de bord analytique.

Abstract

This project, carried out at D&A Technologies for one of its clients specializing in fuel card management, focuses on the design and development of an intelligent fraud detection agent for monetary transactions.

Following the intelligent agent paradigm defined by Russell and Norvig, the system **perceives** its environment through a continuous stream of transactions transmitted via Apache Kafka, **reasons** by jointly applying a seventeen-rule business engine and five Machine Learning models specialized in detecting complex fraudulent behaviors specific to each card's profile, and **acts** by producing a detection decision accompanied by an explanatory description in natural language, generated by the Large Language Model LLaMA 3.3 70B via LangChain. All results are centralized in a PostgreSQL database and made available to business experts through an interactive analytical dashboard.

Compared to the existing system, which relied exclusively on static rules applied in daily batch mode, the solution delivers significant added value : real-time detection, adaptation to individual card profiles, automatic generation of explanations understandable by non-specialist users, and full traceability of the decisions produced.

Keywords : intelligent agent, fraud detection, business rules, large language model, real-time processing, Apache Kafka, analytical dashboard.

Liste des abréviations

Abréviation	Signification
AHP	Analytic Hierarchy Process (Processus d'Analyse Hiérarchique)
API	Application Programming Interface
AUC	Area Under the Curve (Aire sous la courbe)
AUROC	Area Under the Receiver Operating Characteristic Curve
AUPRC	Area Under the Precision-Recall Curve
BI	Business Intelligence
CRM	Customer Relationship Management
CRISP-DM	Cross-Industry Standard Process for Data Mining
CSV	Comma-Separated Values
CV	Cross-Validation (Validation Croisée)
DT	Decision Tree (Arbre de Décision)
ERD	Entity-Relationship Diagram (Diagramme Entité-Relation)
GPU	Graphics Processing Unit
IA	Intelligence Artificielle
IF	Isolation Forest
KPI	Key Performance Indicator (Indicateur Clé de Performance)
LCEL	LangChain Expression Language
LLM	Large Language Model (Grand Modèle de Langage)
LOF	Local Outlier Factor
ML	Machine Learning (Apprentissage Automatique)
NN	Neural Network (Réseau de Neurones)
PO	Product Owner
RF	Random Forest (Forêt Aléatoire)

Abréviation	Signification
ROC	Receiver Operating Characteristic
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SQL	Structured Query Language
SCRUM	Méthodologie de gestion de projet Agile itérative
TPD	Tokens Per Day (Tokens par Jour)
ZDR	Zero Data Retention (Conservation Zéro des Données)

Table des matières

Dédicace	i
Remerciements	ii
Résumé	iii
Abstract	iv
Liste des abréviations	v
Table des figures	x
Liste des tableaux	xi
Introduction générale	1
1 Contexte général du projet	4
1.1 Organisme d'accueil	4
1.1.1 Présentation de D&A Technologies	4
1.1.2 Fiche technique	5
1.1.3 Historique et évolution de D&A	5
1.1.4 Missions de D&A Technologies	6
1.1.5 Organigramme de l'entreprise	7
1.2 Présentation du projet	7
1.2.1 Présentation du client	7
1.2.2 Contexte général et problématique	8
1.2.3 Objectifs du projet	8
1.3 Conduite du projet	9
1.3.1 Méthodologie de développement des modèles : CRISP-DM	9
1.3.2 Méthodologie du travail	11
1.3.3 Outils de communication	12
1.3.4 Planification de projet - diagramme de Gantt	12
2 Analyse des besoins et étude de l'existant	16
2.1 Analyse de l'existant	16
2.2 Processus actuel de détection de fraude	17
2.3 Critique de l'existant	18

2.4	Identification des règles améliorables par l'intelligence artificielle	18
2.5	Les cinq règles améliorables par l'IA	18
2.5.1	Anomalie de montant par rapport à la moyenne historique	18
2.5.2	Plafond mensuel épuisé avant le 15 du mois	19
2.5.3	Fréquence excessive de transactions	20
2.5.4	Inactivité prolongée	20
2.5.5	Baisse de consommation	20
2.6	Spécification des besoins	20
2.6.1	Besoins fonctionnels	21
2.6.2	Diagramme de cas d'utilisation	21
2.6.3	Besoins non fonctionnels	22
2.6.4	Utilisateurs finaux	23
3	État de l'art	24
3.1	Notion de fraude et détection d'anomalies	24
3.2	Fondements du Machine Learning	24
3.2.1	Machine Learning	25
3.3	Méthodes non supervisées pour la détection des anomalies	25
3.3.1	Isolation Forest	25
3.3.2	Local Outlier Factor (LOF)	27
3.4	Méthodes supervisées pour la détection de fraude	29
3.4.1	XGBoost (Extreme Gradient Boosting)	30
3.4.2	Random Forest	33
3.5	Benchmark et développement des modèles de Machine Learning	36
3.5.1	Jeu de données et contraintes de modélisation	36
3.5.2	Modèle 1 — Détection d'anomalies de montant	37
3.5.3	Modèle 2 — Détection du risque d'épuisement de plafond avant le 15	40
3.5.4	Modèle 3 — Détection de fréquence excessive de transactions . .	42
3.5.5	Modèle 4 — Détection des baisses de consommation	45
3.5.6	Modèle 5 — Détection de l'inactivité prolongée	48
3.6	Agents IA pour la détection de fraude	51
3.6.1	La notion d'agent intelligent	51
3.6.2	Le framework ReAct	52
3.6.3	Limites de ReAct dans le contexte du projet et solution proposée	53
4	Conception de la solution proposée	55
4.1	Architecture globale de la solution	55
4.1.1	Vue d'ensemble	55
4.1.2	Description des composants de l'architecture	56
4.2	Sélection du modèle de langage	57
4.2.1	Critères de sélection	57
4.2.2	Méthode AHP	58
4.2.3	Comparaison des modèles candidats	61
4.2.4	Justification du modèle retenu	61
4.3	Conception du tableau de bord de supervision	62

4.3.1	Vue générale	62
4.3.2	Vue de détail des transactions frauduleuses	63
4.4	Conception de la base de données	65
4.4.1	Vue d'ensemble du schéma	65
4.4.2	Description des tables	66
4.4.3	Choix de conception notables	67
5	Réalisation	68
5.1	Technologies utilisées	68
5.1.1	Frameworks et bibliothèques Python	68
5.1.2	Apache Kafka	71
5.1.3	Base de données	71
5.2	Docker	72
5.3	Architecture technique du système de détection de fraude	72
5.4	Chaîne de génération de langage naturel	74
5.4.1	Évaluation des performances du module de génération LLM	75
5.5	Dashboard Streamlit	76
5.5.1	Apport de l'agent intelligent par rapport à l'existant	77
	Conclusion et perspectives	79
A	Prompt complet de génération des descriptions LLM	81
B	Schéma SQL détaillé des tables PostgreSQL	84
	Bibliographie	88
	Sitographie	91

Table des figures

1.1	Logo de D&A Technologies	4
1.2	Le Groupe D&A Technologies en quelques chiffres	5
1.3	Schéma récapitulatif chronologique de l’historique de D&A Technologies	6
1.4	Organigramme de l’entreprise D&A Technologies	7
1.5	CRISP-DM	10
1.6	Cycle de vie selon la méthode SCRUM	12
1.7	Diagramme de Gantt	14
2.1	Processus actuel de détection de fraude	18
2.2	Diagramme de cas d’utilisation du système de détection de fraude	22
3.1	Isolation Forest	27
3.2	LOF principe de fonctionnement	29
3.3	XGBoost principe de fonctionnement	32
3.4	Random Forest principe de fonctionnement	35
3.5	Architecture générale d’un agent intelligent (adapté de [26])	51
4.1	Architecture générale du projet	56
4.2	Schéma hiérarchique reformulant le problème du choix du LLM	59
4.3	Prototype de la vue générale du tableau de bord Première Partie	62
4.4	Prototype de la vue générale du tableau de bord Deuxième Partie	63
4.5	Prototype de la vue de détail des transactions frauduleuses — tableau des transactions	64
4.6	Prototype de la vue de détail des transactions frauduleuses — vue détaillée d’une transaction sélectionnée	65
4.7	Diagramme ERD de la base de données de détection de fraude	66
5.1	Architecture du pipeline de détection de fraude — flux temps réel et flux hebdomadaire	73
5.2	Dashboard Streamlit — Vue générale : indicateurs clés et évolution temporelle des fraudes	76
5.3	Dashboard Streamlit — Vue générale : matrice thermique des scénarios de fraude	76
5.4	Dashboard Streamlit — Vue de détail : tableau des transactions frauduleuses	77
5.5	Dashboard Streamlit — Vue de détail : description générée par le LLM pour une transaction sélectionnée	77

Liste des tableaux

1.1	Fiche technique de D&A Technologies	5
3.1	Caractéristiques de la table historique_transactions	36
3.2	Variables explicatives utilisées par le modèle de détection des anomalies de montant	38
3.3	Benchmark des modèles de détection d'anomalies	39
3.4	Variables explicatives — Modèle 2 (Plafond épuisé avant le 15)	41
3.5	Benchmark des algorithmes — Modèle 2	41
3.6	Variables explicatives utilisées par le modèle de détection de fréquence excessive	43
3.7	Benchmark des algorithmes — Modèle 3 (Fréquence excessive)	44
3.8	Variables explicatives utilisées par le modèle de détection des baisses de consommation	46
3.9	Benchmark des algorithmes — Modèle 4 (Baisse de consommation)	47
3.10	Variables explicatives utilisées par le modèle de détection de l'inactivité prolongée	49
3.11	Benchmark des algorithmes — Modèle 5 (Inactivité prolongée)	50
4.1	Modèles candidats après filtrage préliminaire	58
4.2	Échelle d'importance de Saaty [36]	59
4.3	Matrice de comparaison par paires des critères	60
4.4	Poids normalisés des critères	60
4.5	Évaluation des modèles candidats par critère (échelle 1–10)	61
5.1	Services Docker de l'environnement de développement	72
5.2	Résultats d'évaluation du module de génération LLM	75
5.3	Comparaison entre le système existant et la solution proposée	78
A.1	Variables injectées dans le prompt de génération	81

Introduction Générale

La transformation numérique des secteurs financier et énergétique a profondément modifié les modes de gestion des paiements et des consommations de carburant au sein des entreprises. Dans ce contexte, les cartes carburant sont devenues un service largement proposé par les sociétés de distribution de carburants afin de simplifier la gestion des flottes de véhicules professionnels, de centraliser les dépenses et d'améliorer le suivi des consommations.

Toutefois, la généralisation de ce mode de paiement s'accompagne d'une augmentation des risques de fraude. Ces fraudes peuvent prendre différentes formes, telles que l'utilisation abusive des cartes, les détournements, les transactions anormales ou encore des comportements de consommation inhabituels. Face au volume important de transactions générées quotidiennement, l'identification manuelle de ces comportements devient une tâche complexe, coûteuse et sujette aux erreurs.

Afin de faire face à ces enjeux, les sociétés de distribution de carburants sont amenées à mettre en place des solutions intelligentes capables de surveiller automatiquement les transactions, d'identifier les comportements suspects et de détecter les fraudes en temps réel.

Les systèmes de détection de fraude traditionnellement utilisés reposent principalement sur des règles métiers définies par des experts du domaine. Ces règles permettent de détecter efficacement les scénarios de fraude connus et clairement identifiés. En revanche, elles présentent plusieurs limites. D'une part, elles sont incapables d'identifier de nouveaux types de fraude qui n'ont pas été anticipés lors de leur conception. D'autre part, elles ne prennent généralement pas en considération les habitudes de consommation propres à chaque client. Par conséquent, l'utilisation de seuils fixes ou de règles statiques peut conduire à des faux positifs ou, au contraire, laisser passer certaines fraudes plus subtiles.

Par ailleurs, avec des volumes pouvant atteindre plusieurs centaines de milliers de transactions, une analyse manuelle ou exclusivement fondée sur des règles devient insuffisante. Il apparaît alors nécessaire d'intégrer des techniques d'intelligence artificielle et d'apprentissage automatique capables d'analyser les comportements de consommation, d'apprendre les habitudes normales des utilisateurs et de détecter automatiquement les anomalies.

Dans ce contexte, la problématique de ce projet peut être formulée comme suit :

Comment concevoir un agent intelligent de détection de fraude sur les transactions de cartes

carburant, capable de percevoir en continu le flux de transactions, d'analyser leur légitimité en combinant règles métiers et techniques d'intelligence artificielle, et de produire des décisions de détection explicables en temps réel ?

Afin de répondre à cette problématique, ce projet de fin d'études a pour objectif de concevoir et de développer un système hybride de détection de fraude dédié aux transactions de cartes carburant. Plus précisément, il vise à :

- développer un moteur de règles métiers permettant de détecter les scénarios de fraude connus et les contraintes métiers qui doivent obligatoirement être vérifiées et qui ne peuvent être remplacées par des modèles d'apprentissage automatique ;
- concevoir et entraîner plusieurs modèles de Machine Learning destinés à détecter automatiquement les comportements frauduleux, aussi bien au niveau des transactions individuelles qu'au niveau comportemental des utilisateurs ;
- intégrer un Grand Modèle de Langage (LLM) afin de générer automatiquement une explication claire et détaillée des fraudes détectées, facilitant ainsi leur interprétation par les utilisateurs métier ;
- mettre en place un pipeline de traitement en temps réel permettant la réception, l'analyse et le stockage des résultats de détection pour chaque transaction ;
- développer un tableau de bord interactif offrant une visualisation des indicateurs de fraude ainsi que des fonctionnalités de filtrage et d'analyse selon différents critères, tels que le client, la carte ou la période.

Pour atteindre ces objectifs, une architecture hybride a été proposée en combinant trois approches complémentaires. La première repose sur un moteur de règles métiers garantissant la vérification systématique des contraintes fonctionnelles connues. La deuxième s'appuie sur cinq modèles de Machine Learning, dont quatre modèles non supervisés basés sur l'algorithme Isolation Forest, chacun spécialisé dans la détection d'un type particulier de fraude comportementale, ainsi qu'un modèle supervisé Random Forest destiné à la classification des transactions frauduleuses. Enfin, la troisième approche intègre un système de génération automatique de langage naturel fondé sur le framework LangChain et le modèle LLaMA 3.3 70B afin de produire une description contextuelle des anomalies détectées.

Au-delà de la simple détection de fraude, cette architecture s'inscrit dans le paradigme des agents intelligents. En effet, le système perçoit son environnement à travers un flux continu de transactions transmis par Apache Kafka, analyse chaque transaction en exploitant conjointement les règles métiers et les modèles d'intelligence artificielle, puis agit en produisant des décisions de détection accompagnées d'explications en langage naturel, lesquelles sont ensuite stockées dans une base de données et mises à disposition des utilisateurs via un tableau de bord décisionnel.

Le présent rapport est structuré en cinq chapitres. Le premier chapitre présente l'organisme d'accueil, le contexte général du projet ainsi que la méthodologie de conduite adoptée. Le deuxième chapitre est consacré à l'analyse des besoins et à l'étude de l'existant. Le troisième chapitre expose les fondements théoriques relatifs aux agents intelligents, au Machine Learning ainsi qu'aux différents modèles de détection de fraude

retenus. Le quatrième chapitre détaille la conception et l'architecture générale de la solution proposée. Enfin, le cinquième chapitre présente la réalisation du système, son implémentation ainsi que les résultats obtenus et les différentes interfaces développées.

Chapitre 1

Contexte général du projet

Introduction

Dans ce chapitre, nous présentons une vue d'ensemble de l'organisme d'accueil, D&A Technologies, en mettant en avant ses aspects organisationnels. Nous aborderons également son historique, ses missions, ainsi que quelques indicateurs clés. Par la suite, nous introduirons le contexte général du projet en précisant la problématique identifiée ainsi que les objectifs visés. Enfin, nous décrirons la démarche adoptée pour mener à bien ce travail.

1.1 Organisme d'accueil

1.1.1 Présentation de D&A Technologies



FIGURE 1.1 – Logo de D&A Technologies

Fondée en 2012 au Maroc, D&A Technologies est une entreprise marocaine spécialisée dans le conseil et l'ingénierie digitale. Elle accompagne les organisations dans la transformation, la structuration et l'optimisation de leurs processus métiers en s'appuyant sur des solutions innovantes dans les domaines du Cloud, de la Data et de l'Intelligence Artificielle. Historiquement centrée sur la plateforme Salesforce, l'entreprise dispose d'une équipe de plus de 70 experts certifiés et a réalisé à ce jour plus de 100 projets en Europe et en Afrique. Afin de répondre aux évolutions du marché numérique et aux besoins croissants des entreprises en matière de valorisation des données, D&A Technologies a également renforcé son positionnement dans les domaines de la

Data, de l'analyse de données et de l'Intelligence Artificielle, qui constituent aujourd'hui des axes majeurs de son développement.



FIGURE 1.2 – Le Groupe D&A Technologies en quelques chiffres

1.1.2 Fiche technique

La fiche technique ci-dessous donne les informations clés concernant l'entreprise D&A Technologies.

TABLE 1.1 – Fiche technique de D&A Technologies

Raison sociale	D&A Technologies
Statut juridique	S.A.R.L
Date de création	26 juin 2012
Fondateur & CEO	Driss Lahrichi
Activité principale	Conseil, implémentation, formation Salesforce et mise en place de solutions Cloud
Effectif	51-200 employés
Capital	1 000 000 DHS
Siège social	4 Lotissement la colline, Sidi Maarouf, Casablanca, Maroc
Site web	http://da-technologies.ma/

1.1.3 Historique et évolution de D&A

La figure ci-dessous présente les principales étapes de l'évolution de D&A Technologies depuis sa création en 2012, mettant en évidence une croissance progressive et une adaptation continue aux exigences du marché numérique.




FIGURE 1.3 – Schéma récapitulatif chronologique de l'historique de D&A Technologies

1.1.4 Missions de D&A Technologies

Les activités de D&A Technologies s'articulent autour de plusieurs axes stratégiques visant à accompagner les entreprises dans leur transformation numérique :

- **L'optimisation de l'expérience client** : grâce à l'automatisation des processus, l'analyse des comportements utilisateurs et la personnalisation des interactions à grande échelle.
- **La transformation CRM et digitale** : à travers l'amélioration de la gestion de la relation client, l'optimisation du cycle de vie des clients et l'automatisation des processus métiers au sein des organisations.
- **L'analyse de données et l'Intelligence Artificielle** : en exploitant les données pour générer des indicateurs pertinents en temps réel, développer des modèles prédictifs et concevoir des solutions d'IA adaptées aux besoins spécifiques des clients.
- **L'adoption des technologies Cloud** : par la migration et l'optimisation des infrastructures numériques, ainsi que par la mise en œuvre de pratiques modernes d'intégration continue et de déploiement continu (CI/CD).
- **La formation et l'accompagnement au changement digital** : en renforçant les compétences des collaborateurs à travers des programmes de formation spécialisés et des certifications reconnues, notamment sur la plateforme Salesforce.

1.1.5 Organigramme de l'entreprise




FIGURE 1.4 – Organigramme de l'entreprise D&A Technologies

1.2 Présentation du projet

Le projet réalisé au sein de D&A Technologies s'inscrit dans le cadre d'une mission d'accompagnement d'un client opérant dans le secteur de l'énergie et du carburant. L'objectif principal de ce projet est de contribuer à l'amélioration des mécanismes de surveillance et d'analyse des transactions afin de renforcer la détection des comportements frauduleux.

1.2.1 Présentation du client

Pour des raisons de confidentialité et conformément aux politiques de sécurité de D&A Technologies, l'identité du client ne sera pas divulguée dans ce rapport. Néanmoins, une présentation générale de ses activités est nécessaire afin de mieux comprendre le contexte du projet.

Le client est un acteur majeur dans le domaine des carburants. Dans le cadre de sa stratégie de transformation digitale, il propose à ses clients professionnels une offre monétique innovante basée sur des cartes de paiement dédiées à la gestion des dépenses liées aux flottes de véhicules.

Cette solution vise à fournir de nouvelles modalités de paiement permettant d'améliorer la gestion opérationnelle des flottes tout en offrant une meilleure maîtrise des dépenses en carburant. La plateforme numérique mise à disposition des utilisateurs propose un suivi en temps réel des transactions, un contrôle des budgets alloués ainsi qu'une supervision complète des activités des véhicules. Elle intègre également un module de détection de fraude qui génère, pour chaque transaction, une description précise des types d'anomalies identifiées.

1.2.2 Contexte général et problématique

Comme indiqué précédemment, la détection des transactions frauduleuses et l'identification des comportements anormaux des utilisateurs constituent des fonctionnalités essentielles de l'offre monétique proposée par le client. Ces mécanismes permettent de garantir un niveau élevé de sécurité, tout en offrant aux gestionnaires de flotte un meilleur contrôle de leurs opérations financières.

Dans ce contexte, le projet s'inscrit dans une démarche d'intégration des technologies d'intelligence artificielle et de machine learning afin d'analyser les transactions et les comportements des clients. L'objectif est de détecter les anomalies susceptibles de révéler des activités frauduleuses.

Les équipes du client disposent déjà d'un système de détection reposant sur un ensemble de règles métier prédéfinies permettant d'identifier certains comportements suspects et transactions potentiellement frauduleuses. Cependant, cette approche repose sur des règles statiques, appliquées de manière uniforme à l'ensemble des clients, ce qui limite sa capacité d'adaptation aux différents contextes d'utilisation.

Dans ce contexte, la problématique initiale du projet consistait à étudier comment les techniques d'intelligence artificielle et de machine learning pourraient être intégrées au système existant afin de concevoir une solution plus flexible, capable d'apprendre à partir des données, de s'adapter aux spécificités de chaque client.

1.2.3 Objectifs du projet

Ce projet a pour objectif principal de concevoir une solution de détection de fraude intelligente, fondée sur les technologies du machine learning, qui exploite les données transactionnelles et comportementales pour améliorer les dispositifs de surveillance actuels.

Pour atteindre cet objectif, plusieurs objectifs spécifiques ont été définis :

- Analyser et comprendre les données relatives aux transactions et aux comportements des clients afin d'identifier les caractéristiques pertinentes pour la détection de fraude.
- Étudier les limites du système actuel basé sur des règles métier statiques et identifier les opportunités d'amélioration offertes par les techniques d'intelligence artificielle.
- Développer des modèles de Machine Learning capables de détecter les anomalies et les comportements suspects associés aux différents scénarios de fraude.
- Exploiter les capacités des modèles de langage (LLM) et des agents d'intelligence artificielle afin d'automatiser l'analyse.
- Concevoir et développer un tableau de bord interactif permettant de suivre les fraudes détectées par l'agent intelligent, offrant ainsi une meilleure visualisation des alertes, une analyse synthétique des cas détectés et un support à la prise de décision pour les équipes métier.

1.3 Conduite du projet

1.3.1 Méthodologie de développement des modèles : CRISP-DM

Dans le cadre de notre projet de Data Mining, nous avons adopté la méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining) [37], qui constitue un cadre structuré permettant d’orienter les travaux d’exploration et de modélisation des données en data science. Cette méthodologie est composée de six phases principales :

- **Phase 1 : Compréhension du Business (Business Understanding)** : Cette première étape consiste à définir et comprendre les objectifs métier du projet. Elle permet de :
 - Déterminer les objectifs métier ;
 - Identifier les besoins et contraintes du projet.

Dans notre cas, plusieurs réunions ont été organisées avec l’équipe data responsable du projet afin de bien cerner la problématique et de comprendre précisément les objectifs attendus. Cette collaboration a permis d’aligner la solution technique avec les besoins métier.

- **Phase 2 : Compréhension des données (Data Understanding)** : Cette phase consiste à collecter, explorer et analyser les données disponibles. Elle comprend :
 - La collecte des données initiales ;
 - La description des données ;
 - L’exploration des données ;
 - La vérification de la qualité des données.

Dans notre projet, nous avons identifié les informations nécessaires à l’atteinte de l’objectif, en collaboration avec l’équipe data, qui nous a fourni les tables pertinentes ainsi que les informations associées. De notre côté, nous avons analysé les différentes colonnes, étudié les relations entre les tables et validé les jeux de données avec les équipes concernées. Une phase exploratoire a ensuite été réalisée afin de mieux comprendre la structure des données (nombre de colonnes, période couverte, volume de transactions, etc.). Enfin, bien que la vérification de la qualité des données soit généralement essentielle, elle était ici partiellement réduite car les données étaient déjà nettoyées et issues de la plateforme Databricks.

- **Phase 3 : Préparation des données (Data Preparation)** : Cette étape consiste à transformer les données brutes en un format exploitable pour la modélisation. Elle inclut :
 - La sélection des données pertinentes ;
 - Le nettoyage des données ;
 - La construction de nouvelles variables ;
 - L’intégration des données.

Dans notre projet, nous avons procédé au nettoyage des données (suppression des doublons, traitement des valeurs manquantes), au formatage des variables temporelles, à la sélection des colonnes pertinentes ainsi qu’à la normalisation des variables afin de les adapter aux modèles de machine learning.

- **Phase 4 : Modélisation (Modeling)** : Cette phase consiste à appliquer des techniques statistiques et des algorithmes de machine learning. Elle comprend :
 - La sélection des techniques de modélisation ;
 - La définition du protocole de test ;
 - La construction des modèles.

Dans notre cas, nous avons réalisé un benchmark de plusieurs modèles adaptés au problème de détection d'anomalies afin de comparer leurs performances. Les modèles ont été testés sur un même jeu de données, puis évalués selon des critères techniques et métiers. À l'issue de cette comparaison, le modèle le plus performant a été retenu.

- **Phase 5 : Évaluation (Evaluation)** : Cette phase vise à évaluer la pertinence du modèle vis-à-vis des objectifs métier. Elle consiste à :
 - Évaluer les résultats obtenus ;
 - Revoir le processus si nécessaire.

Dans notre projet, nous avons analysé les résultats du modèle afin de vérifier sa fiabilité et sa pertinence métier. Une attention particulière a été portée à l'analyse des cas extrêmes détectés ainsi qu'à la cohérence des anomalies identifiées avec les comportements réels des données.

- **Phase 6 : Déploiement (Deployment)** : Cette phase consiste à mettre en production le modèle ou à exploiter ses résultats dans un environnement opérationnel.

Dans le cadre de notre projet, les modèles de détection des différents types de fraude ont été intégrés dans un agent intelligent, permettant leur application sur des données réelles. Les résultats générés sont ensuite visualisés via un tableau de bord développé avec Streamlit, facilitant ainsi l'analyse et le suivi des anomalies détectées.




FIGURE 1.5 – CRISP-DM

1.3.2 Méthodologie du travail

Dans le cadre du développement de ce projet, nous avons adopté une approche Agile itérative basée sur la méthodologie SCRUM [38]. Cette méthode est largement utilisée au sein des équipes Data au sein de D&A Technologies afin de répondre efficacement à l'évolution continue des besoins métier et d'assurer une meilleure flexibilité dans la réalisation des projets.

Avant de détailler la planification du projet, il est important de rappeler quelques notions clés du vocabulaire SCRUM utilisées :

- **Product Owner (PO)** : Le Product Owner est le représentant du client. Il est responsable de la priorisation du Product Backlog et de la définition des User Stories en fonction des besoins métier.

Dans le cadre de ce projet, ce rôle est assuré par Mme Salma Chafiq, qui a organisé plusieurs réunions avec les équipes métier. Elle a également développé une solution, qui constitue pour nous le système actuel (l'existant), et sur laquelle nous nous basons dans notre projet afin de proposer des améliorations et de nouvelles fonctionnalités.

- **Sprint Backlog** : Le Sprint Backlog correspond à l'ensemble des tâches issues du Product Backlog, sélectionnées et priorisées pour être réalisées durant un Sprint.
- **Sprint** : Un Sprint est une itération de développement permettant d'atteindre des objectifs définis sur une période donnée.

Dans les projets SCRUM classiques, un Sprint dure généralement entre 2 et 3 semaines. Dans le cadre de ce projet, cette durée a été conservée comme référence. Ainsi, la durée de chaque Sprint pouvait varier dans cet intervalle (de 2 à 3 semaines) selon la difficulté et la charge de travail associées aux différentes User Stories.

- **Scrum Master** : Le Scrum Master est responsable de la bonne application de la méthodologie SCRUM et de la coordination de l'équipe.

Dans notre projet, ce rôle est assuré par Mme Samia Naciri, qui organise les réunions quotidiennes (Daily Scrum) d'une durée maximale de 15 minutes, permettant de suivre l'avancement du projet et d'identifier rapidement les blocages.




FIGURE 1.6 – Cycle de vie selon la méthode SCRUM

1.3.3 Outils de communication

Le stage s'étant déroulé selon un mode hybride, à raison de deux jours de travail à distance par semaine, le recours à des outils de communication adaptés s'est avéré indispensable afin d'assurer une coordination efficace entre les membres de l'équipe. Ainsi, l'outil **Slack** a été utilisé pour les échanges quotidiens et le suivi informel des tâches, tandis que **Google Meet** a permis la tenue des réunions quotidiennes (Daily Scrum) ainsi que des différentes réunions de suivi du projet. Par ailleurs, l'outil **Trello** a été utilisé pour la gestion visuelle du Product Backlog et du Sprint Backlog, permettant de suivre l'avancement des tâches à travers différentes colonnes correspondant aux statuts d'avancement.

1.3.4 Planification de projet - diagramme de Gantt

Le projet adopte une approche itérative structurée en plusieurs phases, correspondant aux différents sprints SCRUM. Ces phases ont été définies en fonction des jalons du projet et validées lors des réunions de suivi avec le comité de pilotage, composé principalement de l'encadrante du projet. Le travail a été organisé en cinq sprints principaux :

- **Sprint 1 : Analyse et cadrage du besoin** : cette phase est consacrée à la compréhension du besoin métier ainsi qu'à la définition des objectifs du projet.
- **Sprint 2 : Conception de la solution** : cette étape porte sur la conception de l'architecture globale de la solution et la définition des approches techniques à adopter.
- **Sprint 3 : Étude théorique et état de l'art** : ce sprint est dédié à l'analyse des travaux existants et à l'étude des méthodes et modèles pertinents pour le projet.
- **Sprint 4 : Implémentation technique** : cette phase consiste au développement et à l'implémentation des modèles et des composants de la solution.

Le planning détaillé de l'ensemble des sprints est présenté sous forme de diagramme de Gantt en figure 1.7.




FIGURE 1.7 – Diagramme de Gantt

Conclusion

Ce chapitre a permis de présenter de manière détaillée l'organisme d'accueil D&A Technologies, en mettant en évidence son historique, sa structure organisationnelle ainsi que ses principales missions.

Il a également introduit le contexte général du projet, en présentant le client avec lequel nous collaborons, ainsi que le projet dans sa globalité. La problématique a été exposée, accompagnée des objectifs principaux visant à améliorer la solution actuelle de détection de fraude grâce à l'apport de l'intelligence artificielle et du machine learning.

Enfin, ce chapitre a présenté la méthodologie de travail adoptée, notamment Scrum pour la gestion de projet, CRISP-DM pour la démarche de développement, ainsi que le diagramme de Gantt utilisé pour planifier la réalisation du projet.